

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине «Машинное обучение»

на тему «Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация»

Выполнил:

Студент Качуков Кирилл Дмитриевич
Группа ИПБП41

Проверил:
Дольников Максим Геннадиевич

Ростов-на-Дону

2026 г.

Цель работы и исходные данные

Цель лабораторной работы — изучить методы понижения размерности и кластеризации, оценить информативность исходных признаков, выделить значимые и второстепенные компоненты, исследовать работу алгоритмов на данных сложной пространственной формы и определить возможные аномальные наблюдения.

Исследование выполнено по второму варианту на основании файлов Lab2_Dataset_PCA.xlsx и Lab2_Dataset_Clustering.xlsx. В первом наборе используются столбцы G:L (признаки a, b, c, d, e и метки y), во втором — D:F (признаки a, b и метки y). Данные с отсутствующими значениями исключаются. Все исходные признаки перед применением алгоритмов стандартизируются.

Набор данных	Число объектов	Признаки	Эталонные группы
Понижение размерности	247	a, b, c, d, e	y = 0: 83; y = 1: 82; y = 2: 82
Кластеризация	176	a, b	y = 0: 58; y = 1: 60; y = 2: 58

Во всех методах столбец y исключён из обучающих признаков. В первой части он используется только для цветового отображения эталонных групп; во второй — также для заключительного количественного сравнения найденных кластеров. Обучение с использованием эталонных меток не выполнялось.

Используемые средства

Программа написана на Python. Для обработки табличных данных используется pandas, для вычислений — NumPy и SciPy, для моделей — scikit-learn, для графиков — Matplotlib. Исходный скрипт проекта: lab2_variant2.py. При выполнении формируются двенадцать графических файлов формата Portable Network Graphics (PNG) в каталоге output, а числовые результаты выводятся в терминал.

Порядок выполнения

Сначала вычисляется матрица корреляций и строится матрица разброса, затем анализируются метод главных компонент (Principal Component Analysis, PCA), сингулярное разложение (Singular Value Decomposition, SVD) и анализ независимых компонент (Independent Component Analysis, ICA). После этого сравниваются двенадцать алгоритмов кластеризации, анализируются помеченные как шум точки и проверяется согласованность найденных групп с эталонными метками.

1. Понижение размерности и отбор признаков

1.1. Корреляционный анализ

Для признаков a–e рассчитаны попарные коэффициенты корреляции Пирсона. Наиболее выраженная связь наблюдается между d и e: r(d,e) = 0,964. Также заметна связь a и d: r(a,d) = 0,568. Остальные коэффициенты существенно меньше.

	a	b	c	d	e
a	1,000	−0,039	0,127	0,568	0,327
b	−0,039	1,000	0,024	−0,021	−0,011
c	0,127	0,024	1,000	0,024	−0,014
d	0,568	−0,021	0,024	1,000	0,964
e	0,327	−0,011	−0,014	0,964	1,000

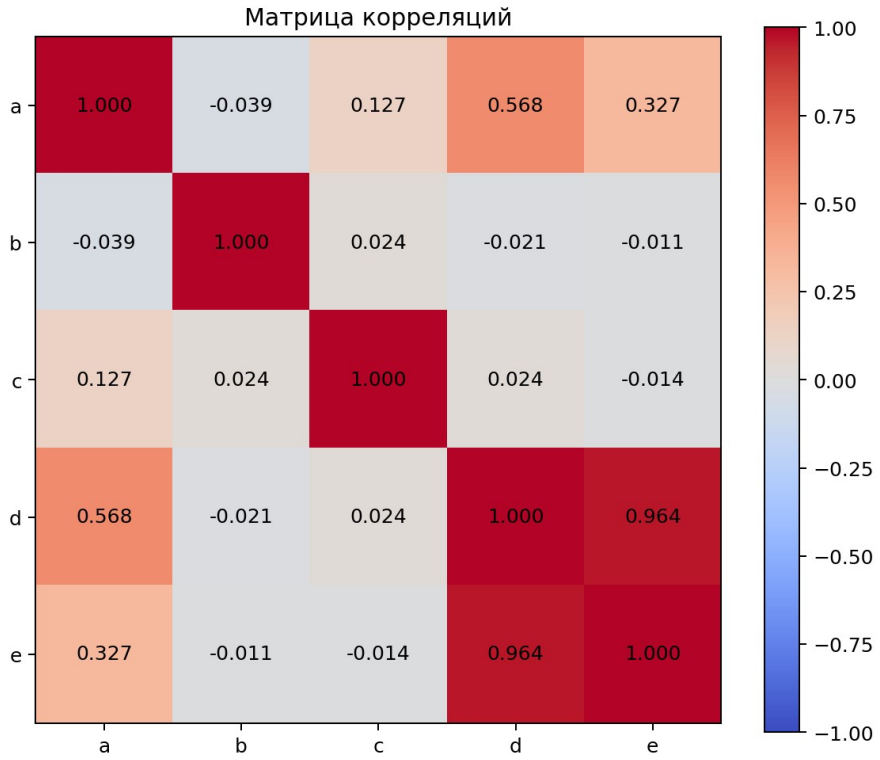


Рисунок 1 — Тепловая карта матрицы корреляций признаков

Очень высокая корреляция d и e указывает на избыточность информации. Дополнительная проверка показала практически точную линейную зависимость e = −0,303609·a + 1,366198·d, поэтому эффективный ранг пяти признаков равен четырём.

1.2. Матрица разброса признаков

Матрица разброса включает диаграммы рассеяния для всех пар признаков и гистограммы по диагонали. Окраска соответствует y и используется только для наглядности. Наиболее выраженный линейный тренд виден для пары d–e.

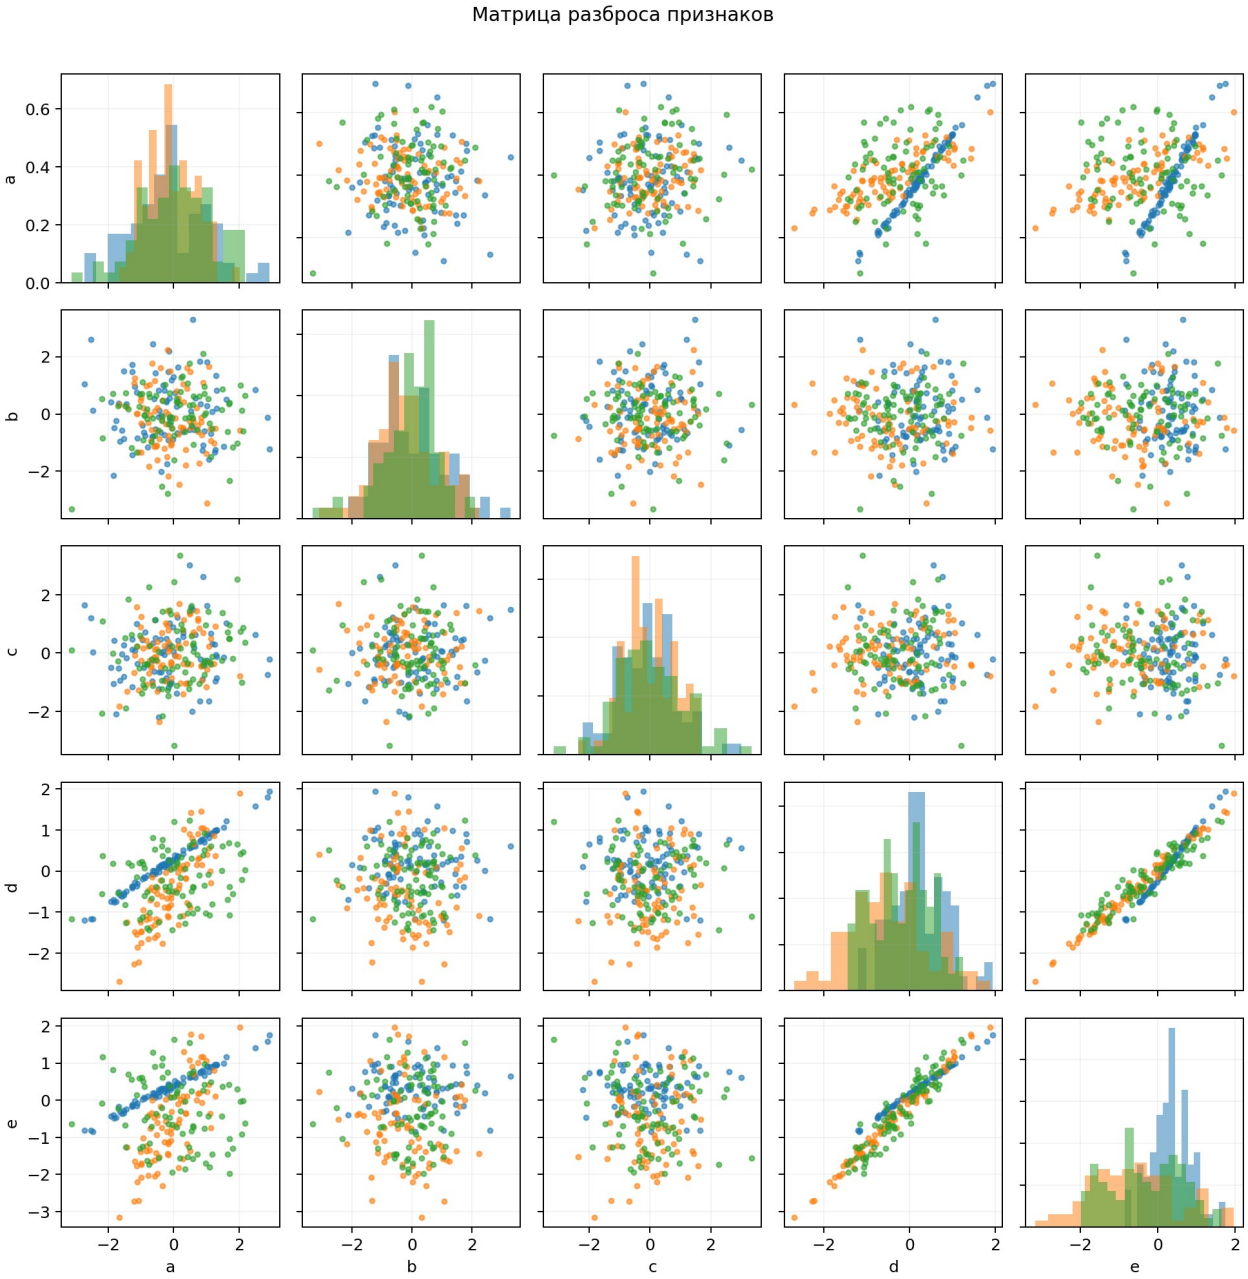


Рисунок 2 — Матрица разброса для пяти исходных признаков

На графиках видно сильное совместное изменение d и e и более умеренную зависимость a от d. Эталонные группы по отдельным признакам и их парам заметно перекрываются. Поэтому для анализа общей структуры используются линейные комбинации исходных переменных.

1.3. Метод главных компонент (PCA)

Перед PCA значения стандартизируются: из каждого признака вычитается среднее, после чего результат делится на стандартное отклонение. PCA находит взаимно ортогональные направления максимальной дисперсии. Их значимость оценивается долей объяснённой дисперсии.

Компонента	Доля дисперсии	Накоплено	Основные нагрузки
PC1	45,68%	45,68%	d = 0,654; e = 0,605; a = 0,449
PC2	20,87%	66,55%	c = 0,890; b = 0,356
PC3	19,92%	86,47%	b = 0,929; c = −0,303
PC4	13,53%	100,00%	a = 0,821; e = −0,426
PC5	≈ 0,00%	100,00%	d = 0,737; e = −0,643

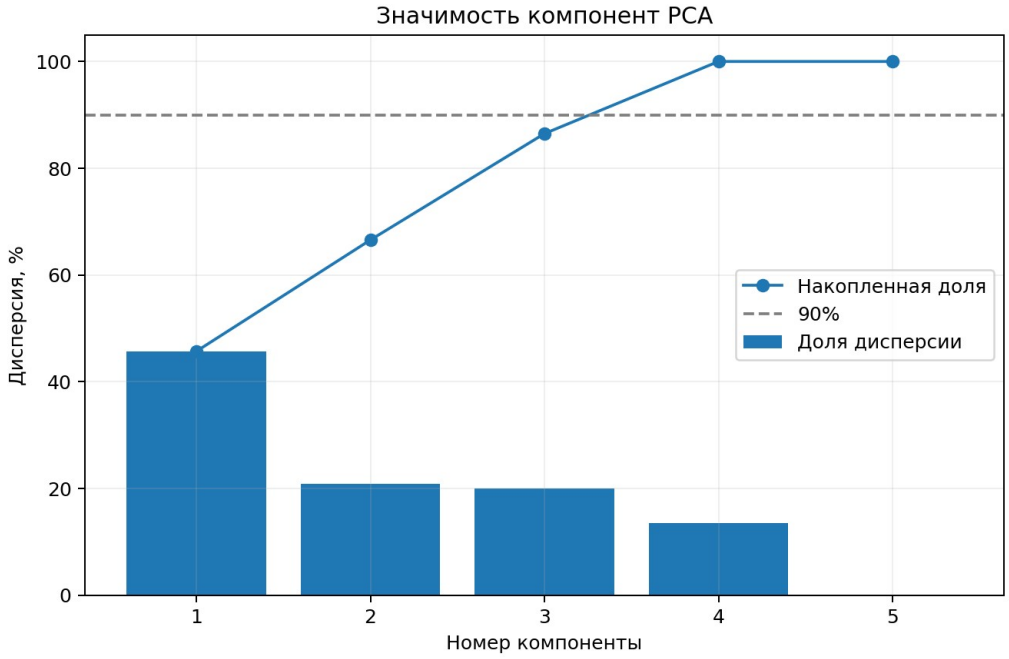


Рисунок 3 — Доля объяснённой дисперсии и накопленная дисперсия PCA

PC1 преимущественно отражает совместное изменение d и e, а PC2 в основном связан с признаком c. Первые две компоненты сохраняют 66,55% дисперсии, первые три — 86,47%. Первые четыре компоненты сохраняют практически 100% вариации. PC5 имеет нулевой вклад из-за точной линейной зависимости исходных признаков и является избыточной компонентой.

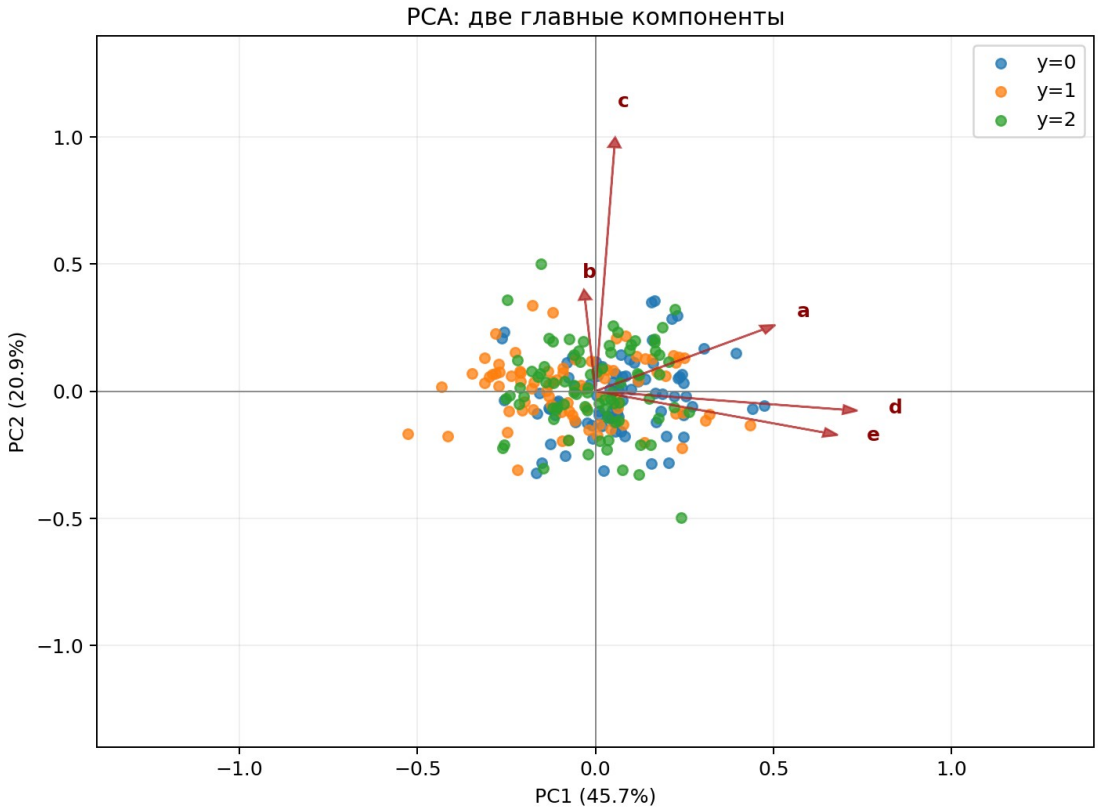


Рисунок 4 — Двумерная проекция PCA с направлениями исходных признаков

На графике векторы d и e ориентированы близко друг к другу, что соответствует их высокой положительной корреляции. Направление c в основном связано со второй компонентой. Эталонные группы частично перекрываются, поэтому две компоненты дают удобное двумерное представление, но не обеспечивают полного разделения классов.

1.4. Сингулярное разложение (SVD)

Метод SVD разлагает матрицу признаков на произведение матриц сингулярных векторов и сингулярных значений. В проекте TruncatedSVD применяется к той же стандартизованной матрице, что и PCA, поэтому доли объяснённой дисперсии практически совпадают.

Результаты SVD по компонентам: 45,68%, 20,87%, 19,92%, 13,53% и ≈0,00%. Первые четыре компоненты сохраняют 100% общей дисперсии; пятая компонента отражает линейную избыточность признаков.

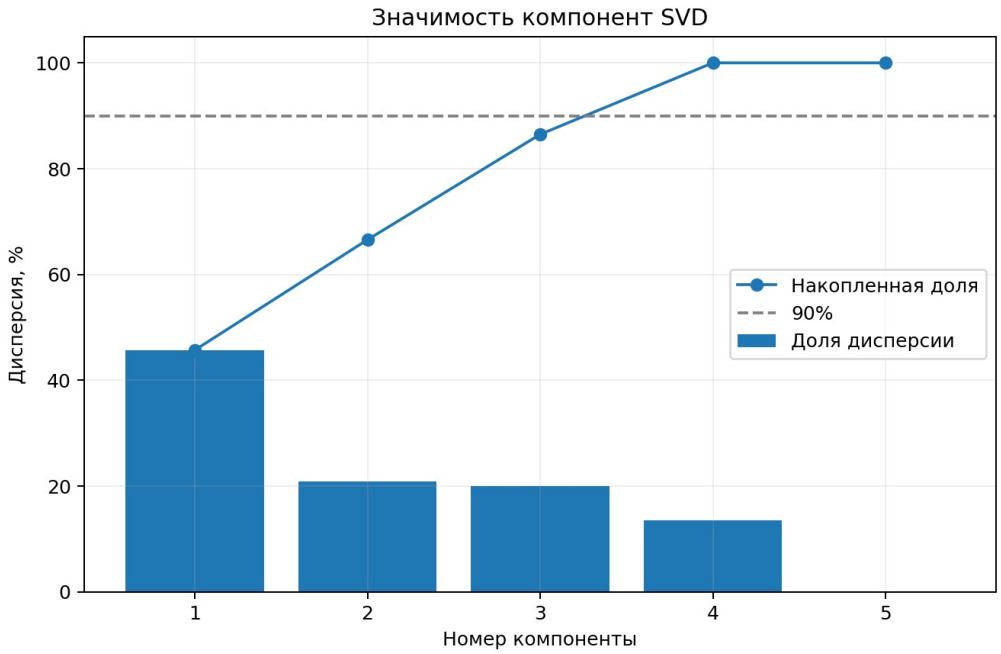


Рисунок 5 — Значимость компонент SVD

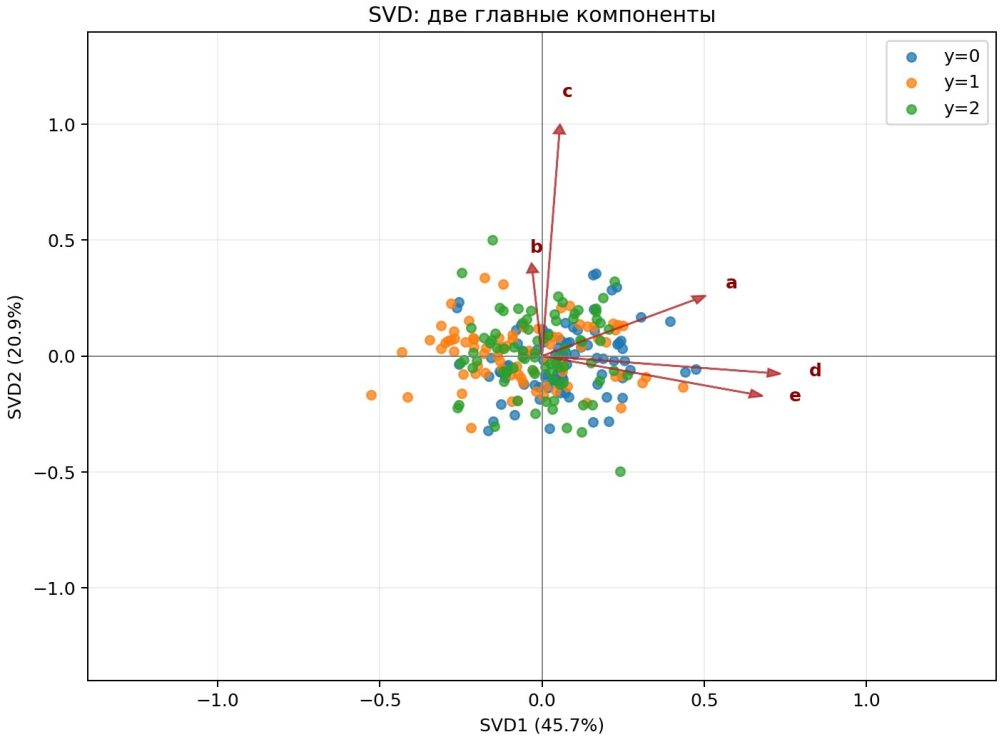


Рисунок 6 — Двумерная проекция SVD с направлениями признаков

Проекция SVD практически совпадает с PCA. Это ожидаемый результат работы с одной и той же стандартизованной матрицей. SVD подтверждает найденную структуру: доминирующее совместное направление d–e, отдельное влияние c и отсутствие самостоятельной пятой компоненты.

1.5. Анализ независимых компонент (ICA)

В отличие от PCA, ICA ищет статистически независимые негауссовские источники. Компоненты FastICA не сортируются по объяснённой дисперсии, поэтому в проекте их значимость сравнивается по энергии вклада в реконструкцию стандартизованных признаков. Дополнительно рассчитан модуль эксцесса.

Компонента	Вклад	|Эксцесс|	Интерпретация
IC3	33,43%	0,512	Наибольший реконструкционный вклад
IC2	28,16%	0,450	Второй по величине вклад
IC4	20,79%	0,457	Умеренный вклад
IC1	17,63%	0,750	Меньший вклад, более выраженная негауссовость
IC5	0,00%	—	Отсутствует: ранг матрицы равен 4

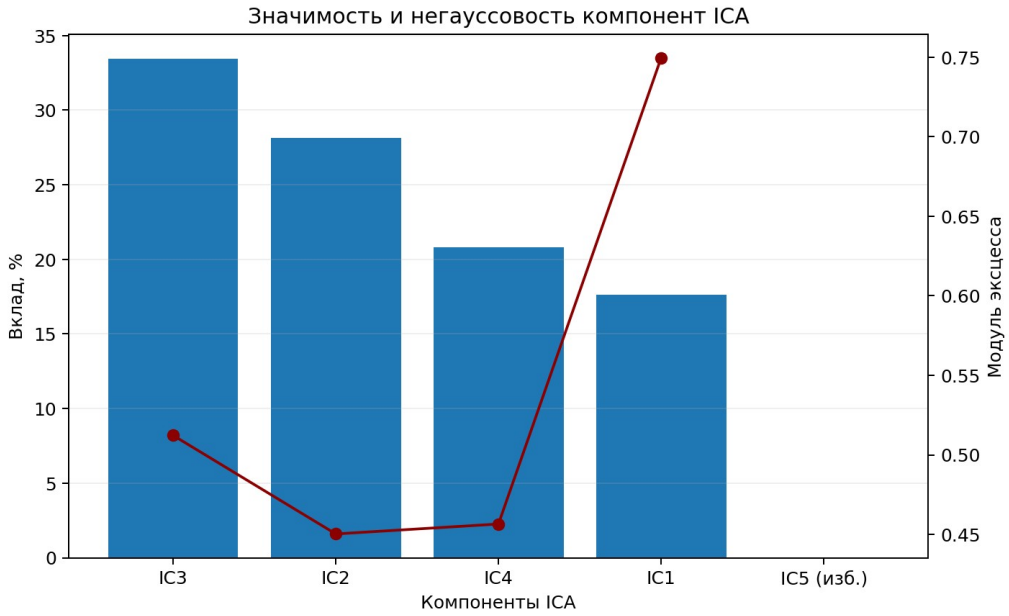


Рисунок 7 — Вклад компонент ICA в реконструкцию и их негауссовость

Две наиболее значимые по выбранной мере компоненты — IC3 и IC2; их суммарный вклад равен 61,59%. IC4 и IC1 имеют меньший вклад. Пятой независимой компоненты не существует: линейная зависимость между исходными признаками уменьшает ранг данных до четырёх.

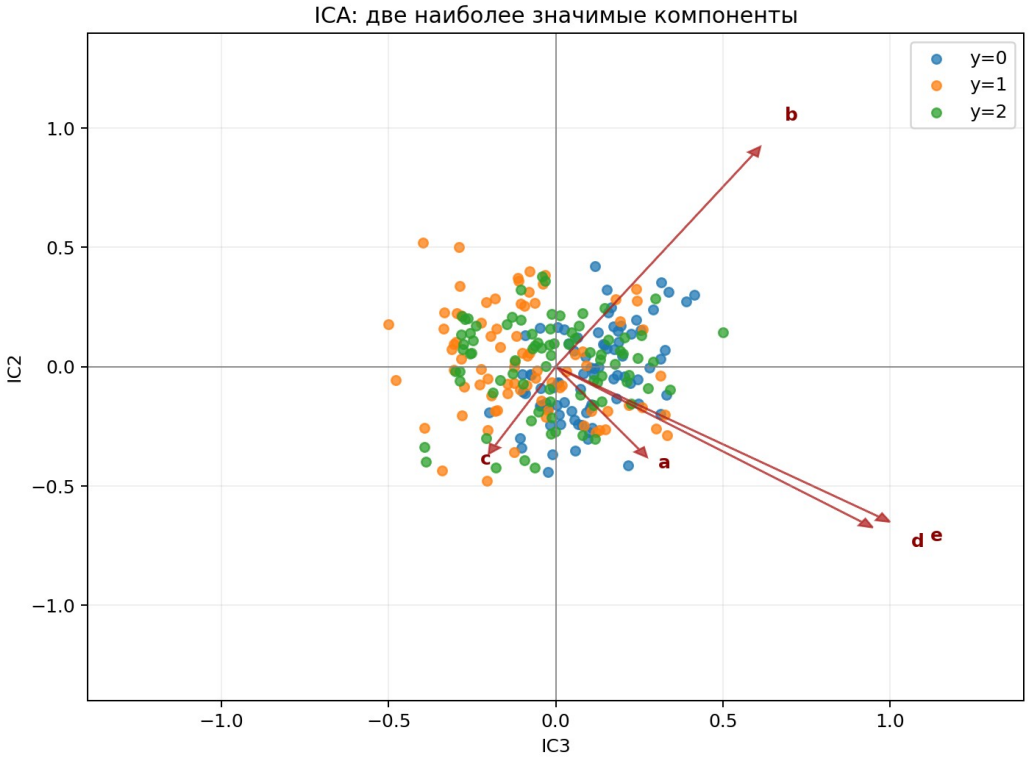


Рисунок 8 — ICA: распределение в координатах IC3 и IC2

Проекция ICA также не разделяет полностью эталонные группы. ICA решает задачу независимости источников, а не максимального разделения классов, поэтому перекрытие точек разных у является ожидаемым.

1.6. Классификация компонент и вывод по первой части

Метод	Главные компоненты	Второстепенные	Наименее значимая
PCA	PC1 и PC2	PC3 и PC4	PC5 (≈0,00%)
SVD	SVD1 и SVD2	SVD3 и SVD4	SVD5 (≈0,00%)
ICA	IC3 и IC2	IC4 и IC1	IC5 отсутствует

При необходимости уменьшить размерность пяти исходных признаков рационально оставить четыре PCA/SVD-компоненты: они сохраняют практически 100% дисперсии. Пятая компонента не содержит самостоятельной информации и обусловлена точной линейной зависимостью признаков.

2. Кластеризация и обнаружение аномалий

2.1. Характер распределения данных и выбор методов

Во второй части исследуется набор из 176 точек с признаками a и b. Эталон содержит три группы. По распределению видны две сравнительно компактные наклонные структуры и более разреженная группа, частично перекрывающая центральную область.

Такая геометрия затрудняет работу методов, предполагающих компактные сферические кластеры. Поэтому наряду с K-Means и иерархическими методами исследуются алгоритмы связности и плотности: Density-Based Spatial Clustering of Applications with Noise (DBSCAN), Hierarchical Density-Based Spatial Clustering of Applications with Noise (HDBSCAN), Ordering Points To Identify the Clustering Structure (OPTICS), а также Balanced Iterative Reducing and Clustering using Hierarchies (BIRCH) и Gaussian Mixture с полной ковариационной матрицей, способный описывать вытянутые компоненты.

2.2. Применённые алгоритмы и параметры

Алгоритм	Основные параметры
K-Means	n_clusters=3; n_init=50
Affinity Propagation	damping=0,85; preference=−13,11
Mean Shift	bandwidth=1,0; bin_seeding=True
Spectral Clustering	n_clusters=3; nearest_neighbors; n_neighbors=10
Ward	n_clusters=3; linkage=ward
Agglomerative	n_clusters=3; linkage=average; metric=euclidean
DBSCAN	eps=0,32; min_samples=10
HDBSCAN	min_cluster_size=12; min_samples=3
OPTICS	min_samples=10; xi=0,05; min_cluster_size=0,08
Gaussian Mixture	n_components=3; covariance_type=full; n_init=50
BIRCH	n_clusters=3; threshold=0,45; branching_factor=20
Bisecting K-Means	n_clusters=3; n_init=20

Параметры подобраны по пространственной структуре данных и внутренним характеристикам без использования y. Для методов с фиксированным числом кластеров задано k = 3. Affinity Propagation самостоятельно сформировал четыре кластера, а плотностные методы при выбранных параметрах выделили по два плотных кластера и значительное число noise-точек.

K-Means, Ward, BIRCH и Bisecting K-Means в большей степени ориентированы на компактные области. Spectral Clustering и Agglomerative учитывают локальную связность, DBSCAN/HDBSCAN/OPTICS — плотность. Gaussian Mixture с полной ковариацией допускает вытянутые кластеры различной ориентации.

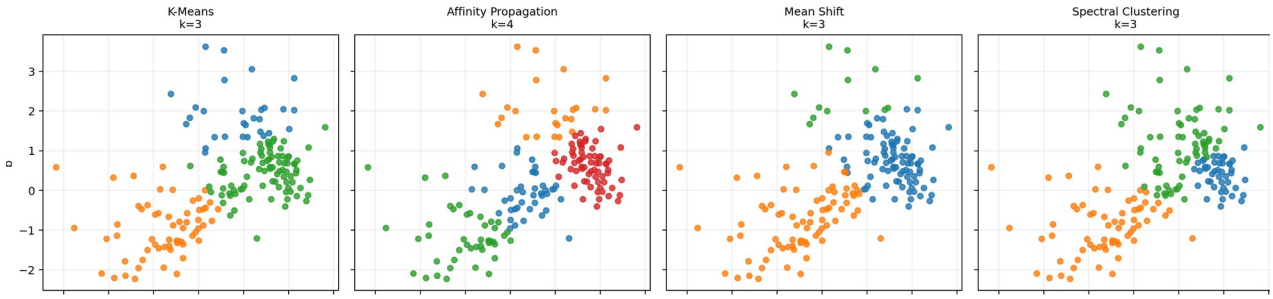


Рисунок 9 — Сравнение: K-Means, Affinity Propagation, Mean Shift, Spectral Clustering

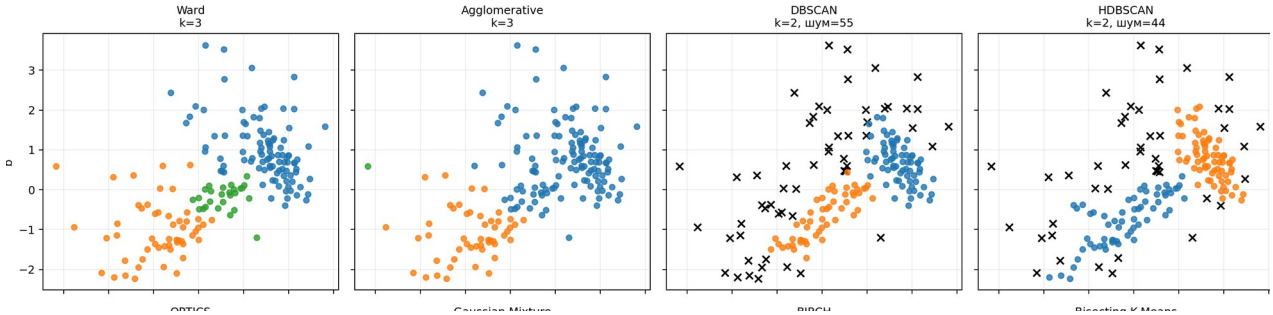


Рисунок 10 — Сравнение: Ward, Agglomerative, DBSCAN, HDBSCAN

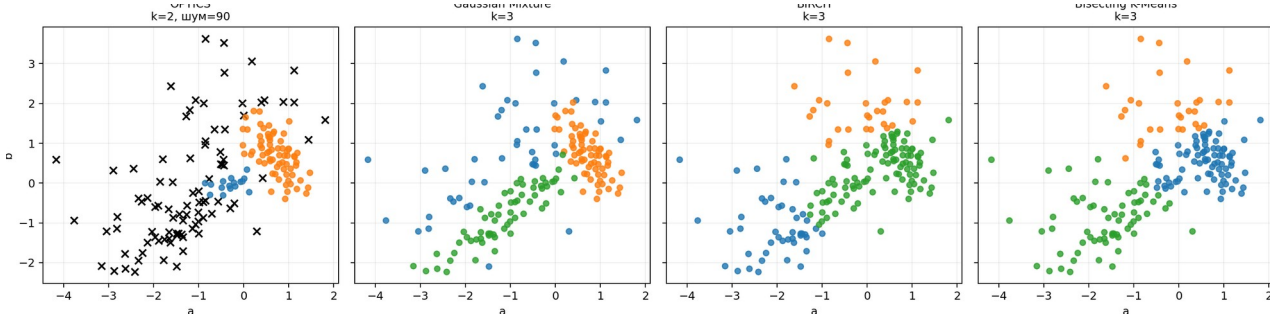


Рисунок 11 — Сравнение: OPTICS, Gaussian Mixture, BIRCH, Bisecting K-Means

По рисункам видно, что центроидные и иерархические методы по-разному разрезают вытянутые ветви. Gaussian Mixture наиболее естественно моделирует наклонные облака. Плотностные методы выделяют две основные плотные структуры, но значительную часть разреженных точек относят к шуму.

2.3. Оценка плотностных методов и обнаружение выбросов

В алгоритмах DBSCAN, HDBSCAN и OPTICS метка −1 означает, что наблюдение не включено ни в один выделенный кластер при выбранных параметрах. Это признак низкой локальной плотности, но не доказательство ошибочности наблюдения.

Алгоритм	Кластеров	Noise, точек	Noise, %	Silhouette без noise
DBSCAN	2	55	31,25%	0,578
HDBSCAN	2	44	25,00%	0,569
OPTICS	2	90	51,14%	0,471

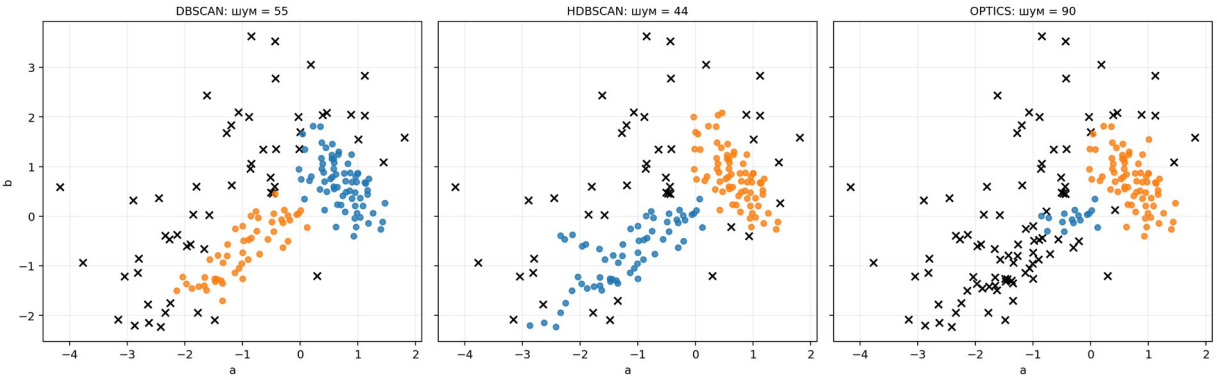


Рисунок 12 — Сравнение найденных кластеров и noise-точек плотностных методов

DBSCAN пометил шумом 55 объектов из 176, HDBSCAN — 44, OPTICS — 90. Высокие значения Silhouette у DBSCAN и HDBSCAN рассчитаны только по точкам, не признанным шумом, поэтому их нельзя интерпретировать без учёта доли исключённых наблюдений.

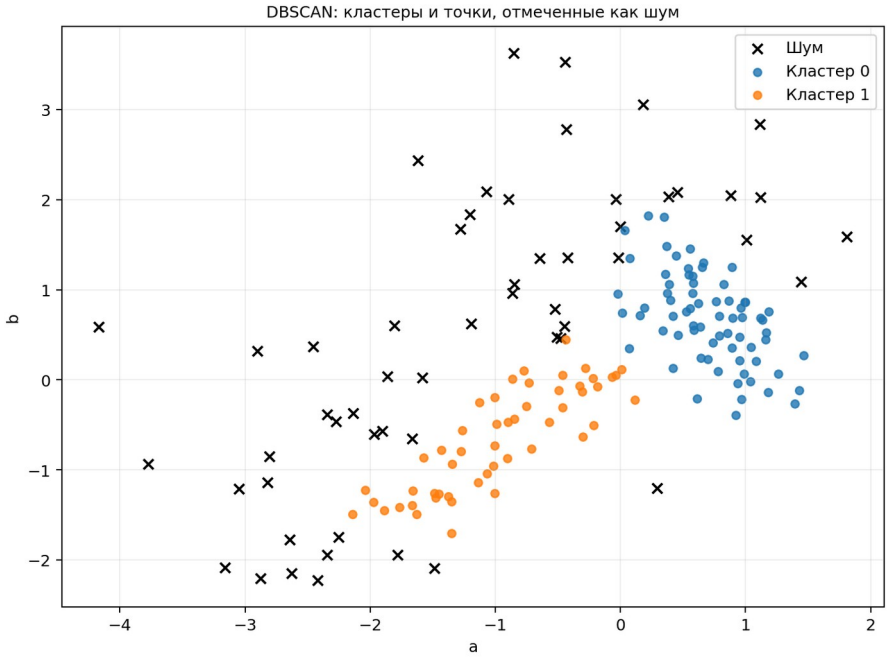


Рисунок 13 — Кластеры DBSCAN; чёрные крестики обозначают потенциальные выбросы

Часть noise-точек лежит в разреженной центральной области и на продолжениях кластерных ветвей. Поскольку в эталонной разметке нет отдельного класса аномалий, эти объекты следует считать потенциальными выбросами, а не подтверждёнными ошибочными наблюдениями.

2.4. Количественное сравнение с эталонными метками

Для проверки качества результатов использованы ARI (Adjusted Rand Index) и NMI (Normalized Mutual Information). Они не зависят от перестановки номеров кластеров. Также рассчитана доля совпадений после оптимального взаимно-однозначного сопоставления найденных кластеров с эталонными классами. Silhouette используется как внутренняя оценка компактности и разделённости.

Алгоритм	k	Noise	Silhouette	ARI	NMI	Совпадение, %
Gaussian Mixture	3	0	0,313	0,488	0,472	78,41
DBSCAN	2	55	0,578	0,416	0,405	73,86
HDBSCAN	2	44	0,569	0,411	0,398	73,30
Mean Shift	3	0	0,456	0,366	0,401	69,32
OPTICS	2	90	0,471	0,362	0,376	63,07
Affinity Propagation	4	0	0,419	0,334	0,369	56,82
Spectral Clustering	3	0	0,345	0,313	0,345	68,75
Bisecting K-Means	3	0	0,443	0,291	0,303	67,61
Ward	3	0	0,307	0,267	0,313	54,55
K-Means	3	0	0,438	0,233	0,253	64,20
BIRCH	3	0	0,378	0,141	0,191	58,52
Agglomerative	3	0	0,489	0,112	0,168	51,14

Лучший результат по ARI получил Gaussian Mixture: ARI = 0,488, NMI = 0,472, доля совпадений 78,41%. Далее следуют DBSCAN и HDBSCAN, однако они формируют только два кластера и исключают значительную часть наблюдений как шум.

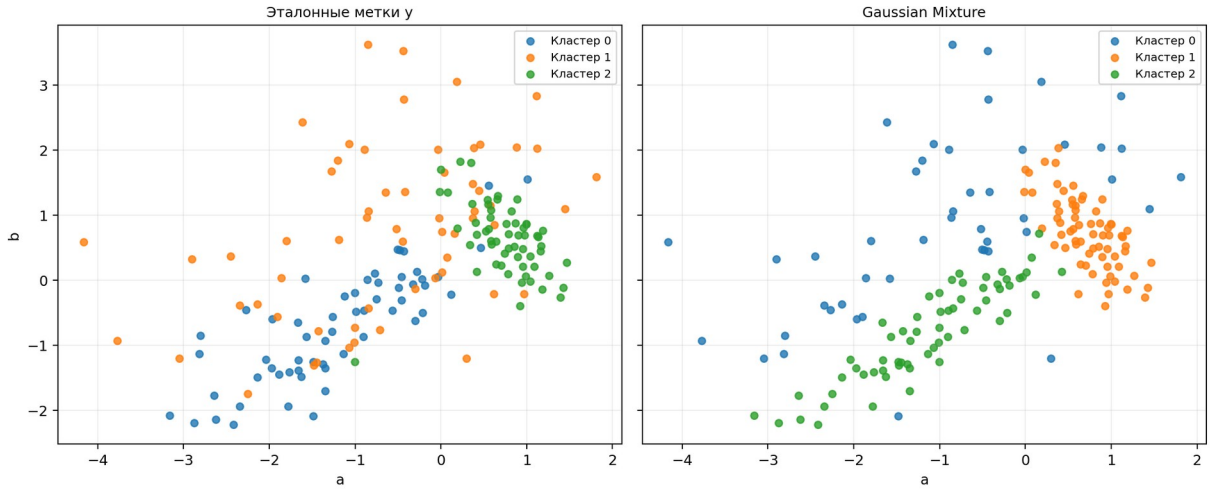


Рисунок 14 — Эталонная разметка и результат Gaussian Mixture

Gaussian Mixture с полной ковариационной матрицей хорошо воспроизводит две вытянутые ветви. Основная ошибка связана с более разреженной эталонной группой, которая пространственно перекрывается с остальными и частично распределяется между компонентами модели.

Значение Silhouette для Gaussian Mixture составляет 0,313 и не является максимальным среди рассмотренных методов. Противоречия нет: Silhouette оценивает геометрическую компактность по расстояниям, тогда как ARI и NMI сравнивают полученное разбиение с эталонными метками. Плотностные методы получают высокий Silhouette на оставшейся части данных, одновременно исключая многие сложные точки.

2.5. Выбор наиболее эффективного алгоритма

Наиболее эффективным из рассмотренных методов для второго варианта признан Gaussian Mixture с тремя компонентами и полной ковариационной матрицей. Он обеспечивает лучшее соответствие эталонной разметке: ARI = 0,488, NMI = 0,472 и 78,41% совпадений после оптимального сопоставления номеров кластеров. Для данного набора важна возможность моделировать вытянутые группы и различный разброс по направлениям.

Методы DBSCAN и HDBSCAN полезны прежде всего для поиска малоплотных областей: они обнаруживают 55 и 44 потенциальных выброса соответственно, но при этом восстанавливают только два плотных кластера вместо трёх эталонных. OPTICS исключает более половины объектов, поэтому для полного разбиения набора менее пригоден.

Заключение

В ходе лабораторной работы проанализирован набор пяти признаков методами корреляционного анализа, PCA, SVD и ICA, а также сравнены двенадцать методов кластеризации двумерного набора данных.

Корреляционный анализ выявил очень сильную связь d и e (0,964). Дополнительная проверка установила точную линейную зависимость e от a и d, поэтому ранг стандартизованной матрицы равен четырём. PCA и SVD согласованно показали, что первые четыре компоненты сохраняют практически 100% дисперсии, а пятая компонента имеет нулевой вклад. В ICA из-за того же ограничения существует только четыре независимые компоненты; наиболее значимы IC3 и IC2.

Во второй части наилучшее соответствие эталону получил Gaussian Mixture (ARI = 0,488; NMI = 0,472; совпадение 78,41%). Плотностные методы успешно находят разреженные точки, но значительная доля noise и уменьшенное число кластеров ограничивают их пригодность для полного восстановления эталонного разбиения.

Использованные материалы

Методические указания: «Лабораторная работа 2. Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация».

Исходные данные проекта: Lab2_Dataset_PCA.xlsx, Lab2_Dataset_Clustering.xlsx (вариант 2).

Программная реализация проекта: lab2_variant2.py; графики из каталога output.

Документация библиотек scikit-learn, SciPy, NumPy, pandas и Matplotlib.